



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

TP 3: Métodos Iterativos

Noviembre 24, 2022

Métodos Numéricos

Grupo 18

Integrante	LU	Correo electrónico
Vekselman, Natán	338/21	natanvek11@gmail.com
Arienti, Federico	316/21	fa.arianti@gmail.com
Lakowsky, Manuel	511/21	mlakowsky@gmail.com
Kovo, Brian	1218/21	brian.ilank@gmail.com



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (+54 +11) 4576-3300

<http://www.exactas.uba.ar>

RESUMEN

Los *métodos iterativos* representan una forma alternativa y eficiente para la resolución de sistemas lineales. Dadas las condiciones necesarias, permiten aproximar el resultado de un sistema en tiempo aproximadamente cuadrático, sin amortización. Es decir, logran una complejidad menor a la que se logra con la mayoría de los otros métodos convencionales —como lo son aquellos que requieren un paso previo de factorización—, cuyo costo no amortizado suele ser cúbico.

En este trabajo evaluaremos la eficiencia de dos métodos iterativos: el método de *Jacobi* y el método de *Gauss-Seidel*, como alternativas para la resolución del algoritmo de *PageRank* —desarrollado en el tp1— sobre una serie de casos de test. Para ello, se propondrá una posible implementación en C++ de ambos métodos y se contrastará su eficiencia con una tercera implementación basada en el método de la *eliminación gaussiana con sustitución inversa*.

A su vez, extenderemos éste análisis para evaluar el comportamiento de los tres métodos en función de la *densidad* del grafo de entrada, para distintas familias de redes.

Palabras clave: método de Jacobi, Gauss-Seidel, Eliminación Gaussiana, PageRank.

CONTENIDOS

1. Introducción teórica	2
1.1. Métodos iterativos	2
1.2. Implementación	3
1.2.1. Método de Jacobi	3
1.2.2. Método de Gauss-Seidel	4
1.2.3. Eliminación Gaussiana y representación de matrices	5
1.2.4. ¿Por qué usamos <i>vector<SparseVector></i> como representación?	6
2. Evaluación de Convergencia	8
2.1. Casos de test	8
3. Evaluación temporal	13
3.1. Casos de test	13
3.2. En función de la densidad del grafo de entrada	14
4. Conclusiones	19

1. INTRODUCCIÓN TEÓRICA

1.1. Métodos iterativos. Los *métodos iterativos* son procedimientos que nos permiten resolver algunos sistemas de ecuaciones lineales del tipo $\mathbf{A}x = b$. Contrario a los *métodos exactos* —como la *Eliminación Gaussiana*— que obtienen su resultado en un número finito de pasos, los métodos iterativos generan una sucesión $\{x^{(k)}\}_{k \in \mathbb{N}_0}$ que, de converger, lo hace a la solución del sistema.

Como esquema básico, dado un $x^{(0)}$ inicial, se define de manera genérica una sucesión iterativa $\{x^{(k)}\}_{k \in \mathbb{N}_0}$ de la siguiente manera:

$$(1) \quad x^{(k+1)} = \mathbf{T}x^{(k)} + c$$

donde \mathbf{T} se denomina *matriz de iteración* y c es un vector. En particular, $x^{(k)}$ va a converger a la solución de un sistema, para cualquier vector $x^{(0)}$ inicial, si y sólo si el radio espectral de la matriz de iteración \mathbf{T} es menor a 1. Es decir:

$$(2) \quad \rho(\mathbf{T}) = \max\{|\lambda| : \lambda \text{ autovalor de } \mathbf{T}\} < 1$$

En este informe, trabajaremos con los métodos de *Jacobi* y *Gauss-Seidel* para la resolución de sistemas $\mathbf{A}x = b$. Estos descomponen a la matriz \mathbf{A} de la siguiente forma:

$$(3) \quad \mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$$

donde \mathbf{D} es la diagonal de \mathbf{A} , \mathbf{L} contiene los elementos negados por debajo de la misma y \mathbf{U} los elementos negados por encima.

Los esquemas para ambos métodos son los siguientes:

Método de Jacobi

$$(4) \quad x^{(k+1)} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})x^{(k)} + \mathbf{D}^{-1}b$$

Método de Gauss-Seidel

$$(5) \quad x^{(k+1)} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}x^{(k)} + (\mathbf{D} - \mathbf{L})^{-1}b$$

Se puede demostrar que, de converger, ambos métodos lo harán a la solución del sistema pedido. Requerimos adicionalmente, para su aplicación, que \mathbf{A} sea una matriz sin elementos nulos en la diagonal. De lo contrario, no se podrán calcular las inversas de \mathbf{D} y $\mathbf{D} - \mathbf{L}$.

1.2. Implementación.

1.2.1. *Método de Jacobi.* Definamos la siguiente aridad para una implementación posible del Método de Jacobi:

$$jacobi : matriz_{n \times n} \mathbf{A} \times vector_n b \times nat\ q \times real\ t \longrightarrow vector_n x$$

donde n es un natural, \mathbf{A} es una matriz con elementos distintos a cero en la diagonal, q es un número que indica la cantidad máxima de iteraciones a realizar y $t \geq 0$ representa la tolerancia mínima a partir de la que se considera la convergencia de una solución.

Si la matriz $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$, satisface que $\rho(\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})) < 1$, entonces el método de Jacobi convergerá a una solución del sistema $\mathbf{A}x = b$. Proponemos el siguiente algoritmo:

```

1 proc jacobi(in A: matriz<n, n>, in b: vector, in q: Nat, in t: Real) {
2
3   x := aleatorio(n)    // un vector aleatorio no nulo, ||x||2 = 1
4
5   i := 0
6   while i < q and ||z||2 ≥ t {
7     y := x
8     j := 0
9     while j < n {
10      s := 0
11      k := 0
12      while k < n {
13        if k != j {
14          s := s + A[j][k] * y[k]
15        }
16        k := k + 1
17      }
18      x[j] := (b[j] - s) / A[j][j]
19      j := j + 1
20    }
21    z := x - y
22    i := i + 1
23  }
24
25  return x
26 }
```

ALGORITMO 1. Pseudocódigo para el *Método de Jacobi*.

Notamos que la complejidad del algoritmo es del orden de $\Theta(q * n^2)$ en el peor caso. En consecuencia, se debe precisar con cuidado la cantidad de iteraciones a realizar para que el factor q sea despreciable. Del mismo modo, una selección de t correcta, acorde al uso, puede resultar en mejoras considerables en la complejidad promedio.

1.2.2. *Método de Gauss-Seidel*. De manera similar, definimos la siguiente función que implementa el Método de Gauss-Seidel:

$$\text{gauss_seidel} : \text{matriz}_{n \times n} \mathbf{A} \times \text{vector}_n \mathbf{b} \times \text{nat } q \times \text{real } t \longrightarrow \text{vector}_n \mathbf{x}$$

donde, nuevamente, n es un natural, \mathbf{A} es una matriz con elementos distintos a cero en la diagonal, q es un número que indica la cantidad máxima de iteraciones a realizar y $t \geq 0$ representa la tolerancia mínima a partir de la que se considera la convergencia de una solución.

Si la matriz $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$, satisface que $\rho((\mathbf{D} - \mathbf{L})^{-1}(\mathbf{U})) < 1$, entonces el método de Gauss-Seidel convergerá a una solución del sistema $\mathbf{A}\mathbf{x} = \mathbf{b}$. Proponemos el siguiente algoritmo, similar al anterior:

```

1 proc gauss_seidel(in A : matriz<n, n>, in b : vector,
2                     in q : Nat, in t : Real) {
3
4     x := aleatorio(n)    // un vector aleatorio no nulo, ||x||2 = 1
5
6     i := 0
7     while i < q and ||z||2 ≥ t {
8         y := x
9         j := 0
10        while j < n {
11            s := 0
12            k := 0
13            while k < n {
14                if k != j {
15                    s := s + A[j][k] * x[k]
16                }
17                k := k + 1
18            }
19            x[j] := (b[j] - s) / A[j][j]
20            j := j + 1
21        }
22        z := x - y
23        i := i + 1
24    }
25
26    return x
27 }
```

ALGORITMO 2. Pseudocódigo para el *Método de Gauss-Seidel*.

Nuevamente, su complejidad temporal es $\Theta(q * n^2)$ en el peor caso.

Observamos que ambos algoritmos aplican ciertas heurísticas que pueden ayudar a reducir su complejidad temporal. Por un lado, se utiliza un vector inicial aleatorio con norma $L_2 = 1$. Esto nos permite evitar aquellas entradas que causan un comportamiento de peor caso de

manera determinística, a costas que una ejecución particular del algoritmo pueda resultar menos eficiente de manera aleatoria. Por el otro lado, se considera la norma L_2 entre dos soluciones consecutivas, como medida de similitud, para definir un quiebre temprano en la iteración externa de los algoritmos en función del parámetro t .

1.2.3. *Eliminación Gaussiana y representación de matrices.* Por último, para poder realizar una comparación entre los *métodos iterativos* y los *métodos exactos*, propondremos una representación de matriz adecuada y un algoritmo eficiente de *eliminación gaussiana* con *sustitución inversa* para la resolución de *PageRank*.

Dadas las cualidades ralas de las matrices asociadas al problema, decidimos trabajar con la siguiente representación: un vector de vectores *sparse* de la biblioteca *Eigen*, que se implementa sobre un esquema CRS —*compressed row storage*— para el indexado a memoria. En el apartado (1.2.4.) explicamos en más detalle esta decisión.

En tanto su implementación, proponemos los siguientes algoritmos para *eliminación gaussiana* y *sustitución inversa*, que aprovechan las herramientas que brinda *Eigen*:

```

1 proc eliminacion_gaussiana(inout A: vector<SparseVector>,
2                           inout b: vector, in ε: Real) {
3
4     n = filas(A)
5     for (i = 0; i < n-1; ++i) {
6
7         mii = A[i].coeff(i)
8         for (j = i+1; j < n; ++j) {
9
10            mij = A[j].coeff(i) / mii
11            if (|mij| < ε) {
12                continue
13            }
14            A[j] = (A[j] - A[i] * mij).pruned(1, ε)
15            b[j] = b[j] - b[i] * mij
16        }
17    }
18 }
```

ALGORITMO 3. Pseudocódigo para la *Eliminación Gaussiana*.

donde $\text{filas}(\mathbf{A})$ refiere a una función que retorna la cantidad de filas en la matriz \mathbf{A} , $v.\text{coeff}(i)$ refiere a un acceso al i -ésimo elemento del vector v y $v.\text{pruned}(\alpha, \varepsilon)$ es una función que reemplaza los elementos explícitos en la memoria del vector v con valor absoluto menor a $\alpha \cdot \varepsilon$ con un cero implícito.

Notamos que la utilización de la función *pruned* permite mantener una matriz esparsa a lo largo del proceso de eliminación a costas de una pérdida de precisión en los resultados. Por ello, una buena selección de ε es fundamental para el buen funcionamiento del algoritmo.

Su interpretación es la siguiente: la tolerancia ε denota el mínimo valor a considerar no nulo durante el proceso de eliminación.

```

1 proc sustitucion_inversa(in A: vector<SparseVector>,
2                        in b: vector) {
3
4     x = b    // vector solucion
5
6     for (i = filas(A) - 1; i ≥ 0; --i) {
7
8         parcial = 0
9         for (iterador(A[i]); it; ++it) {
10             if (pos(it) < i + 1) {
11                 continue
12             }
13             parcial += it.coeff() * x[pos(it)]
14         }
15         x[i] = (x[i] - parcial) / A[i].coeff(i)
16     }
17
18     return x
19 }

```

ALGORITMO 4. Pseudocódigo para *Sustitución Inversa*.

El algoritmo (4.), por su parte, utiliza las funciones *iterador*(v), que retorna un iterador sobre los elementos no nulos del vector v , y *pos*(it), que retorna la posición —contando ceros— a la que está apuntando el iterador it .

1.2.4. *¿Por qué usamos vector<SparseVector> como representación?* Nuestra primera implementación ‘naive’ de la *Eliminación Gaussiana* con Eigen se puede apreciar en el Algoritmo (5.).

A pesar de ser un código sencillo, creíamos que al usar las funciones de la biblioteca y la representación *SparseMatrix* podríamos obtener una ventaja en velocidad. Pero la hipótesis fue claramente refutada con los tiempos que obtuvimos: el test *15_segundos*, por su cuenta, demoró tres minutos y trece segundos en ejecutar en una de nuestras máquinas.

Observamos que la asignación de la línea 13 es una operación muy ineficiente. Esto tiene bastante sentido, ya que *SparseMatrix* está implementada usando *CRS* y por ende todos los elementos se encuentran contiguos en un único vector. Insertar y editar un índice en el medio de éste es un proceso costoso.

Concluimos de la observación anterior que, en caso de tener un *vector<SparseVector>* —donde podamos hacer reemplazos de una fila por otra considerablemente rápido—, además de seguir aprovechando las operaciones optimizadas que provee *Eigen*, podríamos acelerar

considerablemente el algoritmo. Teniendo esto en mente, probamos la implementación detallada en el apartado anterior.

```

1 void eliminacion_gaussiana(SparseMatrix<double> &A,
2                             vector<double> &b, double ε) {
3
4     n = A.rows();
5     for (i = 0; i < n-1; ++i) {
6
7         mii = A.coeff(i, i);
8
9         for (j = i+1; j < n; ++j) {
10             mij = A.coeff(j, i) / mii;
11             if (abs(mij) < ε) continue;
12
13             A.row(j) = (A.row(j) - A.row(i) * mij).pruned(1, ε);
14             b[j] = b[j] - b[i] * mij;
15         }
16     }
17 }
```

ALGORITMO 5. Código C++ de la primera implementación de *Eliminación Gaussiana*.

Esta estrategia resultó considerablemente mejor, ya que —en nuestras máquinas— resuelve correctamente el test *15_segundos* en aproximadamente 2.5 segundos y el test *30_segundos* en 5, dado¹ $\varepsilon = 10^{-5}$.

¹Un comentario necesario es que los tiempos mencionados dependen de ε . Esto es relevante ya que modificar esta variable cambia considerablemente la velocidad del algoritmo. Por ejemplo, con $\varepsilon = 10^{-4}$ el algoritmo termina ambos tests en menos de un segundo, pero con $\varepsilon = 10^{-6}$, demora 6 segundos en el de 15 y 11 en el de 30. No profundizaremos en cómo varía la velocidad respecto a ε .

2. EVALUACIÓN DE CONVERGENCIA

2.1. Casos de test. Evaluamos² el error absoluto en norma L_1 de los resultados de nuestra implementación de *PageRank* sobre el *método de Jacobi* y el *método de Gauss-Seidel* para los casos de test provistos por la cátedra³, en función de la cantidad de iteraciones realizadas.

Notamos que las matrices asociadas a la resolución de *PageRank* son estocásticas en columna, por lo que ambos métodos siempre convergerán a una solución⁴.

METODOLOGÍA. Se evaluó el error absoluto $\|x - \text{pagerank}(g, p)\|_1$, donde x refiere a la solución verdadera, g refiere al grafo de entrada y p al valor p^5 utilizado, para cada caso de test provisto, en función de la cantidad de iteraciones q a realizar en el rango $[1, 100]$.

Se realizó el experimento diez veces para dos implementaciones del algoritmo que difieren únicamente en el método de resolución del sistema lineal asociado a *PageRank*. En la primera se utilizó el *método de Jacobi* y en la segunda el *método de Gauss-Seidel*. Se controló la tolerancia ($t = 0$) para forzar a los algoritmos a iterar de manera exacta.

RESULTADOS. Las figuras (1.) a (7.) muestran los resultados del error absoluto L_1 para cada caso de test.

Notamos que la implementación de *PageRank* sobre el *método de Gauss-Seidel* tuvo una velocidad de convergencia mayor a la que logró la implementación sobre el *método de Jacobi*.

Además, para este primer método, bastó $q < 60$ para lograr un error absoluto L_1 menor a 10^{-6} para todos los casos de test. En cambio, el *método de Jacobi* requirió en un sólo caso más iteraciones para alcanzar la misma meta: el test *15_segundos*. Notamos también que para esta cantidad de iteraciones, la desviación estándar entre las distintas corridas del experimento fue menor a 8.29×10^{-5} . En particular, para los tests *15_segundos* y *30_segundos*, notamos que la cantidad de iteraciones requeridas para converger no parece depender de manera estricta del tamaño de la matriz, pero sí parece existir una correlación.

Consideramos, también, que la meseta de error observado por debajo de 10^{-6} debe corresponder a un error de redondeo entre las soluciones esperadas y las computadas durante el experimento. Sin embargo, observamos que esta meseta no ocurre, en particular, para el test *completo*.

Dadas las limitaciones de esta evaluación —por la escasa cantidad de casos de test—, poco se puede decir respecto al comportamiento general de ambos métodos. Como futura hipótesis a investigar, un estudio más detallado podría evaluar la velocidad de convergencia en función de otros parámetros, como el tamaño de la matriz, la densidad o el valor p utilizado.

²El script asociado se puede encontrar en `./experimentos/convergencia.py`, los archivos resultado en `./experimentos/resultados/convergencia-iterativos`

³Los mismos se pueden encontrar en `./catedra/tests-pagerank`

⁴se puede demostrar que los métodos propuestos convergen para matrices estrictamente diagonal dominantes, las matrices estocásticas en columna son una variante de este tipo.

⁵Para una explicación en más detalle de PageRank, ver el *tp1*.




FIGURA 1. Error absoluto L_1 para el grafo del test *15_segundos*, con $n = 2000$ y $p = 0.9$, en función de la cantidad de iteraciones realizadas, para ambas implementaciones de *PageRank* (escala logarítmica).




FIGURA 2. Error absoluto L_1 para el grafo del test *30_segundos*, con $n = 3000$ y $p = 0.8$, en función de la cantidad de iteraciones realizadas, para ambas implementaciones de *PageRank* (escala logarítmica).




FIGURA 3. Error absoluto L_1 para el grafo del test *desordenado*, con $n = 5$ y $p = 0.76$, en función de la cantidad de iteraciones realizadas, para ambas implementaciones de *PageRank* (escala logarítmica).

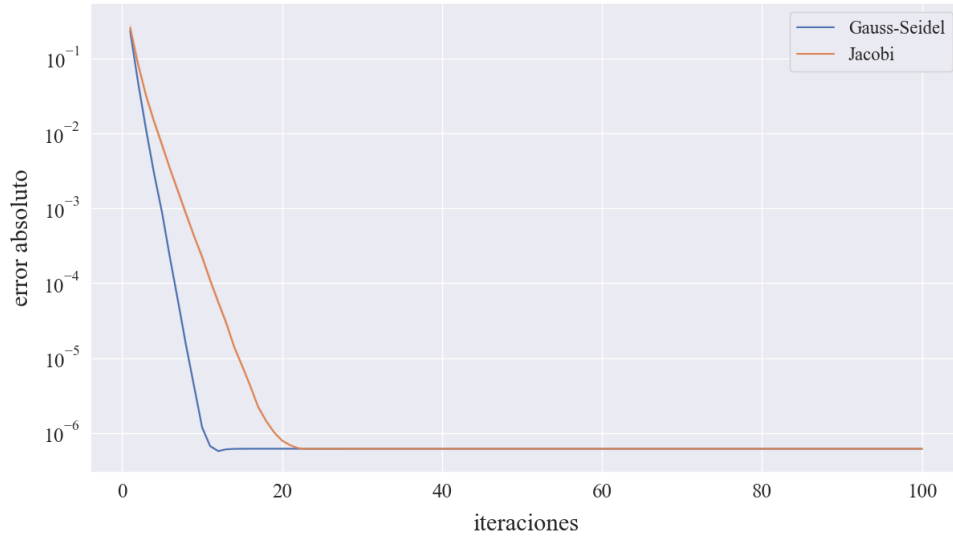


FIGURA 4. Error absoluto L_1 para el grafo del test *aleatorio*, con $n = 5$ y $p = 0.76$, en función de la cantidad de iteraciones realizadas, para ambas implementaciones de *PageRank* (escala logarítmica).




FIGURA 5. Error absoluto L_1 para el grafo del test *completo*, con $n = 5$ y $p = 0.5$, en función de la cantidad de iteraciones realizadas, para ambas implementaciones de *PageRank* (escala logarítmica).




FIGURA 6. Error absoluto L_1 para el grafo del test *sin.links*, con $n = 5$ y $p = 0.64$, en función de la cantidad de iteraciones realizadas, para ambas implementaciones de *PageRank*.




FIGURA 7. Error absoluto L_1 para el grafo del test *trivial*, con $n = 1$ y $p = 0.3$, en función de la cantidad de iteraciones realizadas, para ambas implementaciones de *PageRank*.

Procedemos a mostrar el promedio de los resultados finales para el error absoluto con norma L_1 y L_∞ —para hacer una comparación por coordenadas—, tras las cien iteraciones:

test	Jacobi		Gauss-Seidel	
	L_1	L_∞	L_1	L_∞
15_segundos	1.45×10^{-6}	9.76×10^{-9}	6.4×10^{-7}	5×10^{-9}
30_segundos	7.54×10^{-7}	5×10^{-10}	7.54×10^{-7}	5×10^{-10}
aleatorio	6.18×10^{-7}	2.52×10^{-7}	6.18×10^{-7}	2.52×10^{-7}
aleatorio_desordenado	6.18×10^{-7}	2.52×10^{-7}	6.18×10^{-7}	2.52×10^{-7}
completo	0	0	0	0
sin_links	0	0	0	0
trivial	0	0	0	0

FIGURA 8. Error absoluto L_1 y L_∞ de los casos de test para las implementaciones de *PageRank* sobre los métodos de *Jacobi* y *Gauss-Seidel*.

3. EVALUACIÓN TEMPORAL

3.1. Casos de test. Para comenzar el análisis sobre el tiempo de ejecución de cada uno de los métodos, decidimos inicialmente estudiar cómo se comportan frente a los test de la cátedra.

METODOLOGÍA. Se realizó el cálculo de *PageRank* sobre la implementación que utiliza la *eliminación gaussiana*, con $\varepsilon = 10^{-6}$, y se calculó $\|x - \text{pagerank}(g, p)\|_1$ donde x refiere a la solución verdadera provista por cada uno de los tests. Cabe destacar que este es un proceso determinístico.

A partir de este resultado realizamos una búsqueda de la tolerancia ideal, para el *método de Jacobi* y el *método de Gauss-Seidel*, que nos permitiera calcular *PageRank* con un error similar al obtenido anteriormente. Para esto, se realizó —para ambos métodos— una búsqueda binaria donde en cada paso alteramos la tolerancia t y calculamos el resultado de *PageRank*. Editamos los límites de la tolerancia acorde a si el error calculado fue mayor o menor al error que se cometió con la *eliminación gaussiana*. Repetimos el proceso hasta que la diferencia entre ambas soluciones fue menor a $10^{-2} \times \varepsilon$ en norma L_1 .

Dados estos parámetros, se procedió a calcular *PageRank* para cada test, sobre cada implementación y medir el tiempo de ejecución de la etapa de resolución del sistema lineal asociado⁶. Repetimos este paso diez veces para atenuar las fluctuaciones de tiempo⁷.

RESULTADOS. Procedemos a detallar los resultados en la Figura (9.).

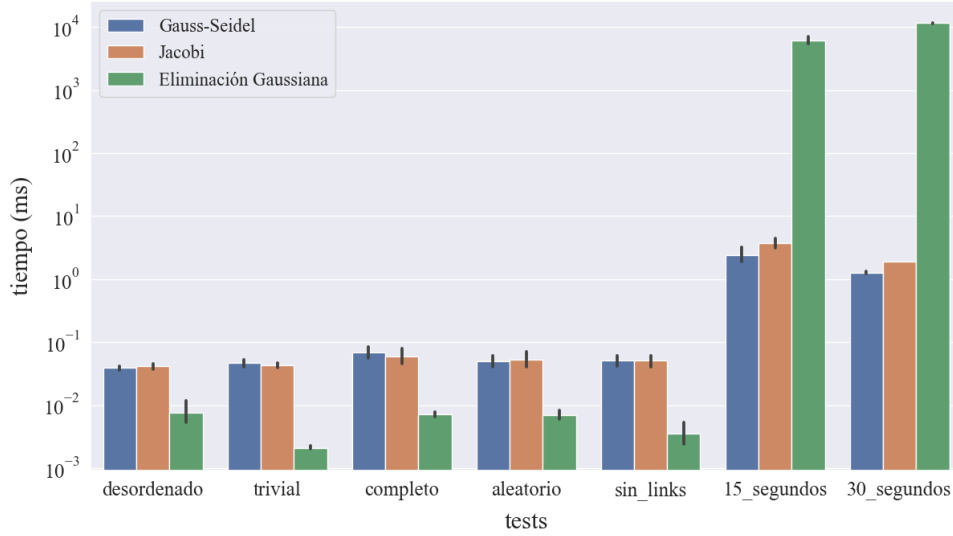


FIGURA 9. Tiempo de ejecución —en milisegundos— de las distintas implementaciones de *PageRank* para cada uno de los tests de la cátedra (escala logarítmica).

⁶Sobre esta medición importan dos aclaraciones: 1. se omitió el tiempo de construcción del sistema lineal asociado —de orden $\Theta(n^2)$ — para poder enfocar en los algoritmos bajo estudio. 2. la medición se realizó dentro del mismo ejecutable de *PageRank* para evitar el ruido que podría ocasionar medirlo de manera externa. Es decir, por medio de una llamada a un subproceso.

⁷Para evitar disparidades sobre los resultados de este experimento, y el subsiguiente, aclaramos que estos se ejecutaron en una misma computadora.

Como se puede apreciar en el gráfico, el *método de Gauss-Seidel* y el *método de Jacobi* son considerablemente más rápidos cuando el tamaño de la matriz es grande. Para el test *30_segundos*, estos métodos tardaron alrededor de dos milisegundos, mientras que la *eliminación gaussiana* tardó más de diez segundos. Sin embargo, cuando el tamaño de la matriz es chico, notamos que la *eliminación gaussiana* es más rápida.

Por su parte, los métodos iterativos tienen una velocidad muy similar. El *método de Gauss-Seidel* fue apenas más rápido que el *método de Jacobi* en todos los casos evaluados.

3.2. En función de la densidad del grafo de entrada. Más allá de los tests de la cátedra, es importante evaluar el comportamiento de los métodos propuestos en función de sistemas alternativos.

En particular, es esperable que el rendimiento de *PageRank* varíe según las cualidades inherentes al tipo de grafo sobre el que se lo ejecute. Para poner esto en práctica vamos a generar un conjunto de entradas y analizar su comportamiento en virtud de su densidad. Es decir, dadas ciertas familias de grafos (ver figura 10.), produciremos instancias aleatorias de ellas con diferentes proporciones de aristas —links— entre sus nodos.




FIGURA 10. Ejemplos de las familias de grafos generadas.

METODOLOGÍA. Para cada familia de grafos generamos siete instancias aleatorias, con densidad creciente $d \in \{0.01, 0.05, 0.1, 0.3, 0.5, 0.9, 1\}$. Estas muestras son aleatorias en tanto los n nodos que participan se seleccionan al azar por medio del algoritmo *sample* de la biblioteca estándar *random* de *python*. Dado un n grande podemos prever una descripción ejemplar de cada categoría bajo estudio.

En concordancia con la sección anterior, evaluamos la implementación de *Eliminación Gaussiana* de *PageRank* con $\varepsilon = 10^{-6}$ y repetimos el proceso de búsqueda binaria, en base al error relativo $\|\mathbf{A}x - x\|_1$ ⁸, —donde \mathbf{A} es la matriz asociada al sistema lineal de *PageRank* y x es la solución obtenida—.

Se utilizó $n = 1000$ y se iteró por cada d y por cada familia de grafos. En cada caso, y para cada implementación, se obtuvieron los parámetros correctos y se midió el tiempo de ejecución de la etapa de resolución del sistema lineal asociado. Se repitió el experimento diez veces para capturar su variabilidad. Además, se controló el valor p ($p = 0.5$).

RESULTADOS. A simple vista, confirmamos la conclusión de la sección previa: los métodos iterativos son considerablemente más rápidos que la *eliminación gaussiana*.

El caso de las redes aleatorias (figura 11.) pone en manifiesto el comportamiento generalmente esperado: el tiempo de ejecución crece en proporción a la densidad del grafo. Los tres métodos mantienen prolijamente su eficiencia relativa. Este comportamiento se refleja también en el resto de las figuras, si bien pierden esta nitidez. Es decir, la precedencia —en tiempo de ejecución— de cada método se mantiene en general, pero no siempre es tan clara como en el caso de los grafos aleatorios.




FIGURA 11. **Aleatorio.** Tiempo de ejecución para el conjunto *aleatorio* de grafos, con $n = 1000$ y $p = 0.5$, en función de la densidad de conexiones, para cada implementación de *PageRank*.

⁸Notamos que esta medida es válida ya que *PageRank* equivale al cálculo del autovector asociado al autovalor en módulo máximo, $|\lambda| = 1$, de \mathbf{A} . Para más detalle ver el *tp1* y *tp2*.

Las redes *sumidero* (figura 12.) y los grafos *estrella* (figura 14.), en particular, muestran tiempos de ejecución muy similares para los métodos de *Jacobi* y *Gauss-Seidel*.

También, cabe destacar la variación inesperada para matrices particularmente ralas, como podemos notar en las redes *sumidero* y *viborita* (figura 15.). Por el otro lado, para grafos *completos* (figura 13.), la distinción es clara: *Gauss-Seidel* es el más rápido, siempre.




FIGURA 12. **Sumidero.** Tiempo de ejecución para el conjunto de redes *sumidero*, con $n = 1000$ y $p = 0.5$, en función de la densidad de conexiones, para cada implementación de *PageRank*.




FIGURA 13. **Completo.** Tiempo de ejecución para el conjunto de grafos que conecta cada nodo con todos los demás, con $n = 1000$ y $p = 0.5$, en función de la densidad de conexiones, para cada implementación de *PageRank*.




FIGURA 14. **Estrella.** Tiempo de ejecución para el conjunto de grafos que conecta un nodo con todos los demás, con $n = 1000$ y $p = 0.5$, en función de la densidad de conexiones, para cada implementación de *PageRank*.




FIGURA 15. **Viborita.** Tiempo de ejecución para el conjunto de redes *viborita*, con $n = 1000$ y $p = 0.5$, en función de la densidad de conexiones, para cada implementación de *PageRank*.

Lo que se puede concluir de estos resultados es la pertinencia de la estructura del grafo que se está analizando. El comportamiento temporal de los métodos propuestos es muy dependiente de la misma, de tal manera que producir una estimación de la eficiencia de *PageRank* podría requerir un estudio puntual al grafo de entrada. No obstante, destacamos, como regla de oro, el predominio del *método de Gauss-Seidel* sobre los otros dos. Donde, incluso si no es el más rápido, exhibe poca desventaja sobre el resto.

4. CONCLUSIONES

A lo largo de este trabajo hemos evaluado distintos métodos para la resolución de sistemas lineales. Particularmente, nos concentramos en la aplicación de la *eliminación gaussiana* y de los métodos de *Gauss-Seidel* y *Jacobi* en el contexto del algoritmo de *PageRank*.

Con el objetivo de medir sus velocidades de ejecución, planteamos una serie de experimentos que nos permitieron estudiar el comportamiento de las distintas implementaciones sobre una gran variedad de familias de grafos: redes aleatorias, de sumidero, completas, estrella y viborita. Esto lo realizamos en función de la densidad de las conexiones, sobre el total de los nodos, para cada entrada.

Además, medimos la velocidad de convergencia en función de la cantidad de iteraciones realizadas y la velocidad de ejecución de una serie de casos de test selectos.

Observamos que los métodos iterativos son significativamente más rápidos que la eliminación gaussiana. A modos prácticos, operan en un orden de complejidad temporal menor, si bien la cantidad de iteraciones q puede resultar significativa. Lo que es más, entre ambos métodos iterativos notamos que el método de *Gauss-Seidel* se ejecutó —en términos generales— con mayor velocidad que el método de *Jacobi*. Consideramos que esto se debe a que, dentro de una misma iteración, el primer algoritmo considera datos más recientes que el segundo.

Si bien ambos métodos están restringidos en su aplicación —la *eliminación gaussiana* funciona solo para matrices con factorización LU y los métodos iterativos sólo sobre el conjunto de matrices para los que convergen—, de tener la posibilidad de elección, los algoritmos de *Gauss-Seidel* y *Jacobi* prueban ser más eficientes a la hora de resolver sistemas lineales.